

20 Newsgroups 文本分类评估报告

本报告由 `evaluation/evaluate_models.py` 与 `evaluation/generate_report.py` 自动生成。

1. 数据集说明

20 Newsgroups 是一个英文新闻组文本分类数据集：每个样本是一条新闻组帖子文本；总样本数为 18846（训练集 **11314**、测试集 **7532**）；标签为 20 个主题新闻组类别。

本项目在 `data/data_loader.py` 中通过 `fetch_20newsgroups` 加载该数据集，并按设置移除 headers/footers/quotes 以降低格式噪声。

参数 `remove=('headers','footers','quotes')` 表示在加载阶段移除邮件头、邮件尾签名和历史引用段落，目标是降低与主题无关的格式噪声，避免模型利用发件信息或引用模板而非正文语义进行分类。

2. Baseline 与模型说明

- **tfidf_logreg**: `TfidfVectorizer + LogisticRegression` 的经典稀疏特征分类基线。模型可复用对象文件（例如向量化器、分类器、完整 pipeline）会在训练后保存到磁盘，路径记录在 `modeling/configs/run_tfidf_logreg_metadata.json` 中。
- **llm_classifier**: 基于 Hugging Face 因果语言模型的 zero-shot 分类器，当前记录模型为 `Qwen/Qwen2.5-1.5B-Instruct`。zero-shot 指不在本任务标签上进行参数微调，仅通过提示词让模型直接输出类别标签。

3. 配置说明

- 训练/推理入口: `main.py`（负责串联数据加载、baseline 训练、LLM 推理）。
- 传统基线配置: `modeling/configs/run_tfidf_logreg_metadata.json`（记录样本规模、TF-IDF 参数、LogReg 参数、模型可复用对象文件路径与结果路径）。
- LLM 运行配置: `modeling/configs/llm_run_metadata.json`（记录模型名、设备、量化方式、输入截断阈值、batch size、zero-shot 汇总结果等）。
- 评估输出目录: `evaluation/outputs`（统一存放模型对比评估所需的 JSON/CSV 结果文件）。

4. 全流程结构 (Pipeline)

1. 加载 20 Newsgroups 数据（训练/测试）
2. 训练 TF-IDF + Logistic Regression 基线并保存模型
3. 运行 LLM zero-shot 预测并保存 JSONL 结果
4. 统一评估脚本读取两种模型输出，计算宏平均与按类指标
5. 生成评估对象文件（JSON/CSV）并产出中文 PDF 报告

5. 输出说明

- `evaluation/outputs/metrics_summary.json`: 模型级汇总指标（Macro-Precision / Macro-Recall / Macro-F1 / unknown 占比），用于快速横向对比。
- `evaluation/outputs/detailed_metrics.json`: 细粒度评估结果（逐类指标、混淆矩阵、unknown 计数等），用于诊断误差来源。
- `evaluation/outputs/per_class_metrics.csv`: 20 个类别逐类 Precision/Recall/F1，便于在电子表格中筛选排序。
- `evaluation/outputs/confusion_matrix_*.csv`: 混淆矩阵原始计数表；行表示真实标签，列表示预测标签，单元格为样本数。

6. 评估指标选择说明

本项目使用 **Macro-Precision / Macro-Recall / Macro-F1** 作为核心指标。含义为：先分别计算每个类别的 Precision/Recall/F1，再对 20 个类别做等权平均。这样不会因为某些类别样本更多而主导总分，能够更公平地反映模型在长尾类别上的识别能力。

模型	Macro-Precision	Macro-Recall	Macro-F1	未知预测占比
tfidf_logreg	0.6653	0.6469	0.6450	0.0000
llm_classifier	0.3580	0.1865	0.2001	0.2775

其中，LLM 预测中的 `unknown` 是指：模型输出未能解析为 20 个标准标签之一（例如输出自由文本解释、多个标签混合、或标签拼写/格式不匹配），因此在标签映射阶段被归入“不可映射预测”。

7. 混淆矩阵与误差分析

混淆矩阵用于展示“真实类别 vs 预测类别”的对应关系：对角线越大表示该类识别越准确，非对角线数值越大表示该真实类别更容易被误判到对应列类别。为提高可读性，图中使用 **A~T** 代替长类别名，完整映射见下方表格。

TF-IDF + LogReg 混淆矩阵 (20x20)

真实 \ 预测	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S	T
A	139	3	1	0	4	3	0	3	13	16	1	2	5	10	16	64	14	10	6	9
B	2	261	20	10	12	21	8	4	6	9	0	3	14	3	13	1	2	0	0	0
C	4	28	236	33	15	14	0	2	5	23	0	4	5	4	12	1	3	2	2	1
D	0	16	37	239	26	5	14	6	1	8	1	3	35	0	1	0	0	0	0	0
E	0	9	14	32	246	2	8	13	4	18	3	1	26	1	7	1	0	0	0	0
F	1	58	27	7	4	262	3	1	4	10	0	3	3	3	6	1	0	1	1	0
G	0	3	3	15	12	0	311	11	5	10	1	1	8	1	4	1	2	1	1	0
H	3	3	2	0	2	3	12	265	18	34	2	2	23	6	6	1	8	1	4	1
I	4	2	0	0	2	0	7	28	298	23	0	2	11	3	7	3	7	0	1	0
J	7	4	1	0	1	3	5	1	8	326	22	0	4	2	1	5	0	3	4	0
K	6	1	0	0	0	1	0	1	5	31	341	1	1	1	3	3	2	0	1	1
L	1	14	2	2	2	5	1	4	7	23	1	259	20	5	6	4	23	7	9	1
M	0	22	12	24	16	7	12	15	9	14	2	13	222	10	12	0	2	0	0	1
N	7	15	1	1	1	2	9	8	13	14	3	0	13	279	7	4	5	3	9	2
O	5	9	3	0	2	0	3	6	6	23	1	3	17	12	289	1	3	3	8	0
P	18	5	2	0	1	1	1	3	1	18	2	0	4	9	4	320	1	0	2	6
Q	7	1	2	1	2	0	2	6	9	19	3	9	4	6	8	8	251	4	16	6
R	23	1	2	0	1	0	1	3	9	20	1	2	3	3	3	11	7	273	12	1
S	21	2	0	0	1	1	1	3	7	14	1	5	3	8	10	4	94	10	123	2
T	49	5	1	1	0	2	2	5	8	11	2	1	0	10	5	71	22	8	9	39

颜色深浅: 小 大

LLM 混淆矩阵 (20x20, 仅统计可映射标签)

真实 \ 预测	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S	T
A	39	0	0	0	0	0	0	10	0	6	3	5	33	26	6	106	4	0	0	0
B	4	50	3	8	2	1	19	53	0	2	0	0	89	0	1	19	4	0	1	0
C	1	5	12	62	3	8	11	51	0	9	1	1	89	1	1	35	1	0	4	0
D	1	7	0	32	0	2	13	103	6	20	0	0	79	0	0	20	2	0	1	1
E	2	4	3	48	16	1	13	98	4	18	0	1	55	0	0	17	1	0	1	2
F	5	12	18	18	2	9	16	36	0	7	0	2	95	3	0	20	3	0	2	1
G	2	3	0	2	0	0	77	70	2	7	2	0	2	1	0	43	5	0	0	6
H	1	5	0	16	0	0	5	176	3	10	0	0	64	7	3	18	2	0	0	2
I	3	3	2	5	0	0	6	115	29	18	6	3	60	7	0	31	18	0	2	1
J	3	0	0	1	0	0	1	18	0	174	1	0	41	15	0	25	2	0	1	1
K	1	1	0	3	0	0	0	20	0	63	144	1	14	12	1	32	6	0	0	0
L	12	2	1	1	0	0	2	5	0	4	0	114	86	6	2	56	9	0	1	0
M	5	6	0	10	2	0	8	67	1	20	1	6	148	4	0	15	2	0	2	1
N	2	0	0	1	0	0	1	25	3	24	3	0	49	158	0	25	2	0	0	1
O	5	0	0	1	0	0	0	7	0	9	2	3	86	5	143	16	2	0	1	1

真实 \ 预测	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S	T
P	12	0	0	0	0	0	0	12	4	7	0	26	53	58	1	117	2	0	0	3
Q	11	1	0	0	0	0	0	11	0	20	0	11	32	15	3	130	20	0	4	0
R	8	0	0	0	0	0	0	19	0	3	2	12	12	28	5	167	7	0	2	0
S	8	0	0	0	0	0	1	6	0	11	2	9	42	24	2	114	8	0	2	0
T	14	1	0	0	0	0	0	12	0	9	1	4	27	20	5	86	6	0	1	2

颜色深浅: 小    大

说明: 在按 20 类混淆矩阵展示时, unknown 样本不计入 20x20 方阵, 详细数量见 summary 文件中的 unknown_prediction_rate。

类别缩写映射 (A~T)

缩写	原始类别
A	alt.atheism
B	comp.graphics
C	comp.os.ms-windows.misc
D	comp.sys.ibm.pc.hardware
E	comp.sys.mac.hardware
F	comp.windows.x
G	misc.forsale
H	rec.autos
I	rec.motorcycles
J	rec.sport.baseball
K	rec.sport.hockey
L	sci.crypt
M	sci.electronics
N	sci.med
O	sci.space
P	soc.religion.christian
Q	talk.politics.guns
R	talk.politics.mideast
S	talk.politics.misc
T	talk.religion.misc

TF-IDF + LogReg 主要混淆对

- 1. S (talk.politics.misc) 被预测为 Q (talk.politics.guns): 94 次
- 2. T (talk.religion.misc) 被预测为 P (soc.religion.christian): 71 次
- 3. A (alt.atheism) 被预测为 P (soc.religion.christian): 64 次
- 4. F (comp.windows.x) 被预测为 B (comp.graphics): 58 次
- 5. T (talk.religion.misc) 被预测为 A (alt.atheism): 49 次
- 6. D (comp.sys.ibm.pc.hardware) 被预测为 C (comp.os.ms-windows.misc): 37 次
- 7. D (comp.sys.ibm.pc.hardware) 被预测为 M (sci.electronics): 35 次
- 8. H (rec.autos) 被预测为 J (rec.sport.baseball): 34 次
- 9. C (comp.os.ms-windows.misc) 被预测为 D (comp.sys.ibm.pc.hardware): 33 次
- 10. E (comp.sys.mac.hardware) 被预测为 D (comp.sys.ibm.pc.hardware): 32 次
- 11. K (rec.sport.hockey) 被预测为 J (rec.sport.baseball): 31 次

12. C (comp.os.ms-windows.misc) 被预测为 B (comp.graphics): **28** 次

LLM 主要混淆对

1. R (talk.politics.mideast) 被预测为 P (soc.religion.christian): **167** 次
2. Q (talk.politics.guns) 被预测为 P (soc.religion.christian): **130** 次
3. I (rec.motorcycles) 被预测为 H (rec.autos): **115** 次
4. S (talk.politics.misc) 被预测为 P (soc.religion.christian): **114** 次
5. A (alt.atheism) 被预测为 P (soc.religion.christian): **106** 次
6. D (comp.sys.ibm.pc.hardware) 被预测为 H (rec.autos): **103** 次
7. E (comp.sys.mac.hardware) 被预测为 H (rec.autos): **98** 次
8. F (comp.windows.x) 被预测为 M (sci.electronics): **95** 次
9. B (comp.graphics) 被预测为 M (sci.electronics): **89** 次
10. C (comp.os.ms-windows.misc) 被预测为 M (sci.electronics): **89** 次
11. L (sci.crypt) 被预测为 M (sci.electronics): **86** 次
12. O (sci.space) 被预测为 M (sci.electronics): **86** 次